

Типы локальных экономик России по муниципальным данным СберИндекса: динамическая кластеризация на атрибутированных сетях

Методологический отчёт. Онлайн-конкурс СберИндекса 2026, направление «Кластеризация». Иван Фроловский. Код, конфигурации и интерактивный лендинг — в репозитории проекта (site/index.html).

1. Коротко

- **Объект:** 2 016 муниципальных образований (МО) России с полной историей безналичных потребительских расходов жителей за 24 месяца (январь 2023 — декабрь 2024) по шести категориям трат; к ним привязаны Росстат (население, зарплата, структура занятости по ОКВЭД2), индекс доступности рынков и дорожные расстояния СберИндекса.
- **Сеть:** узел — МО, атрибуты — структура и уровень трат плюс контекст; рёбра — сходство потребительского поведения. Сравнены восемь правил ребра и пять способов разрежения; итоговая сеть — обученный граф (learning graphs from smooth signals), контроль — взаимный kNN.
- **Метод:** KEFRiN (Shalileh & Mirkin, 2022) — K-means, расширенный на feature-rich сети, — и его временное расширение **KEFRiN-T**: на каждом месяце кластеризуется сглаженный срез, вес истории оценивается по данным shrinkage-оценкой AFFECT (Xu, Kliger, Hero, 2014) с фиксированными эффектами узлов и тестом инновации. Метод проверен на синтетических динамических сетях с известной истиной.
- **Результат:** двухуровневая типология — 4 макротипа (крупные и средние города; северные и ресурсные; столичные агломерации; сельские и малые) и 6 подтипов. Макротипы воспроизводятся по бутстрапу с ARI 0,91–0,95, за два года макротип не меняли 89% МО; каждый тип объясняется тремя порогами (общепит $\leq 6\%$ трат, зарплата ≤ 93 тыс. ₽, траты $\leq 25,9$ тыс. ₽/мес) с точностью 80%.
- **Экономическое содержание:** типы различаются структурой трат (доля общепита от 1,6% у сельских до 7,8% у столичных), уровнем (21–47 тыс. ₽ на жителя в месяц), зарплатой (50–128 тыс. ₽) и доступностью рынков; переходы между типами зависят от типа соседей по дорожной сети; разброс уровней трат между МО за два года вырос (сходимости нет). Единственный большой сдвиг структуры — удвоение доли маркетплейсов (9,4% → 19,3%), причём село растёт вдвое быстрее столиц, а внутри сельского и северного типов доли сходятся.
- **Что нового:** (1) KEFRiN-T — эволюционное расширение метода жюри с оценкой веса истории по данным, фиксированными эффектами узлов и тестом инновации, проверенное на синтетике с известной истиной; (2) обученные из данных временные графы вместо ручного правила ребра, с полным сравнением 36 сетей; (3) две линзы — экономическая и чисто поведенческая — с прямым ответом, что в типологии от данных СберИндекса; (4) волна маркетплейсов как единственный большой сдвиг структуры трат и её география; (5) воспроизводимый пакет: один `make all`, контрольные прогоны с нуля, тесты.

Критерий жюри	Где в отчёте	Главное
Объяснение методологии	схема ниже, §3, §5.1–5.2	шесть шагов; KEFRiN-T словами и формулами
Сетевая и атрибутивная структура	§3, §4	8 правил ребра × 5 разрежений, обученный граф, лаги и DTW проверены
Сравнение методов	§5.3–5.5	12 методов на статике, 8 динамических вариантов, синтетика
ICVI	§5.4, §5.5, §10	SW, CH, S_Dbw, AVI, AVU, ANUI, MQ, модульность; сверено с Pattern
Интерпретация, воспроизводимость	§6–9, §11	пороги, профили, переходы, log-t, волна маркетплейсов, две линзы, make all
Визуализация	лендинг site/index.html, рис. 1–6	карта по месяцам и линзам, потоки, паспорт МО, волна



Схема решения: шесть шагов от данных до интерпретации; каждому шагу соответствует раздел отчёта (§2–3, §4, §5, §6–7, §7–9).

2. Данные

Источник	Что взято	Ключ	Покрытие
СберИндекс, «Потребительские безналичные расходы на уровне МО» (архив хакатона Data → Sense, CC BY-SA 4.0)	оценка средних безналичных трат жителя в месяц, Р; категории: продовольствие, здоровье, общественное питание, маркетплейсы, транспорт, все категории	territory_id	2 190 МО, 2023-01...2024-12; 2 016 с полной историей
СберИндекс, индекс доступности рынков 2024	относительный объём доступного внешнего рынка, 0–1000	territory_id	2 004 из 2 016 (99,4%)
СберИндекс, автодорожные связи между МО	расстояние по графу дорог между центрами МО, км	пары territory_id	5,9 млн пар МО
СберИндекс, версионный справочник границ МО (CC BY-SA 4.0)	названия, тип и статус МО, регион, ОКТМО, центры, полигоны	territory_id, ОКТМО	все 2 016 (полигоны для карты)
Росстат, БД ПМО через «Если быть точным» (CC BY 4.0)	численность населения (в т. ч. городского), среднемесячная зарплата и среднесписочная численность по разделам ОКВЭД2 (без малых предприятий), годовые значения 2023–2024	ОКТМО → territory_id	население 2 014 (99,9%), зарплата и занятость 1 996 (99,0%)

Особенности данных, повлиявшие на решения: (1) в публичной API-выгрузке нет идентификатора ряда, одноимённые МО из разных регионов неразличимы — использован архив хакатона с territory_id; (2) в панели нет 12 регионов (Белгородская, Брянская, Курская, Воронежская, Ростовская области, Краснодарский край, Крым, Севастополь, Дагестан, Чечня, Ингушетия, Бурятия); (3) 24 месяца — один полный годовой цикл, поэтому годовые приросты доступны только за 2024 г.; (4) категория «прочее» = все категории – пять названных (медианная доля 28%). Медианные

доли трат: продовольствие 44,8%, маркетплейсы 13,5%, транспорт 5,7%, здоровье 4,9%, общепит 2,6%.

3. Пространство признаков

По месяцам (7 признаков): CLR-координаты долей шести категорий (геометрия Айчисона для композиционных данных) и относительный уровень трат — логарифм трат минус медиана месяца по всем МО (снимает общероссийскую динамику и инфляцию). **Статический профиль 2024** (11): те же CLR, относительный уровень, его волатильность, сезонная амплитуда, средний прирост г/г, тренд доли маркетплейсов. **Контекст** (10): логарифмы населения, зарплаты, доступности рынков; доля городского населения; пять агрегированных долей занятости (сельское хозяйство; добыча; промышленность, энергетика и строительство; рыночные услуги; бюджетный сектор); признак городского округа. Стандартизация по столбцам с обрезкой хвостов на $\pm 4\sigma$ (иначе доля добычи с $8,7\sigma$ доминирует в расстояниях). Для интерпретации все величины возвращаются в исходные единицы.

Обоснование: жюри в собственной работе о профилировании потребления использует композицию трат по категориям как основу сходства; мы дополняем её уровнем и динамикой, а контекст Росстата даёт экономический смысл типам и внешнюю валидацию.

4. Сетевая структура: правила ребра и разрежение

Сравнены восемь определений сходства между МО и пять способов разрежения (scripts/edge_rules.py, 36 сетей):

Правило (разрежение — взаимный kNN15; обученный граф как есть)	Что измеряет	Ассортативность по атрибутивным типам	Доля рёбер внутри региона
косинус z-профиля 2024	похожесть структуры и уровня трат	0,75	0,28
корреляция месячных приростов (за вычетом медианы месяца)	со-движение	0,51	0,26
максимум корреляции по лагам ± 2	опережение/запаздывание	0,45	0,21
DTW относительного уровня (окно 3)	форма траектории уровня	0,51	0,24
6-мерный DTW CLR-композиции	форма траектории структуры	0,74	0,29
дорожная гравитация $\exp(-d/200 \text{ км})$	география	0,43	0,78
SNF-слияние (профиль + со-движение + география)	комбинация	0,56	0,77
обученный граф (Kalofolias 2016; параметризация 2019)	сглаженность признаков на графе	0,80	0,37

Выводы. Правила из разных семейств почти не пересекаются по рёбрам (Жаккар 0,03–0,15): профиль, со-движение, форма траектории и география — разные отношения. Внутри семейства совпадение ожидаемо выше: дорожная гравитация и её SNF-слияние 0,51, корреляция приростов с лагом и без 0,39, косинус профиля и обученный граф 0,34. Со-движение приростов слабо связано со структурным типом МО; география и её слияние делают сеть региональной («типы = регионы»). Из разрежений глобальный порог по плотности дробит сеть на 1 300+ компонент, планарный TMFG даёт

искусственно высокую модульность, disparity-фильтр почти не фильтрует; взаимный kNN15 и обученный граф — рабочие варианты.

Решение: сеть типологии строится по сходству потребительского поведения. Основной граф — обученный из гладких сигналов: $\min_W \sum_{ij} W_{ij} \|x_i - x_j\|^2 - \alpha \sum_i \log d_i + \beta \|W\|_F^2$ при средней степени 15; в среднем 11 МО в месяц (0,5%) остаются изолятами и получают тип только по признакам. По месяцам граф обучается на сигналах каждого месяца (совпадение рёбер соседних месяцев 0,36 против 0,22 у kNN). На нём совместная кластеризация даёт модульность 0,56 против 0,51 на kNN при той же компактности. Корреляционные и дорожные сети используются отдельно: расстояния — для пространственной обусловленности переходов и «сопоставимых соседей». Опережение и запаздывание («один регион опережает другой») мы проверили лаговыми кросс-корреляциями месячных приростов уровня и доли маркетплейсов за вычетом общероссийской динамики: между средними рядами типов при лагах $\pm 1-2$ месяца корреляции не превышают 0,4 по модулю, а у 58–99% МО лучший лаг относительно своего типа равен нулю. На 24 месяцах устойчивых лидеров и последователей нет, поэтому лаговая сеть в типологии не используется.

Время-варьирующее обучение графа с регуляризацией изменений (Yamada, Tanaka, Ortega, 2020) проверено: при степени 15,6 совпадение рёбер соседних месяцев 0,42 и 1–2 изолята; разбиения на нём и на пооконных графах согласуются (AMI 0,90 по месяцам), а межмесячная устойчивость выше (0,97 против 0,93), но ценой более сглаженных сетей; оставлено как вариант в конфигурации. Для сравнения, согласие разбиений на обученном графе и на kNN — тоже 0,91.

5. Методы кластеризации

5.1. KEFRiN — совместная кластеризация признаков и сети

Модель восстановления данных: $y_{iv} = \sum_k c_{kv} s_{ik} + f_{iv}$ (признаки), $p_{ij} = \sum_k \lambda_{kj} s_{ik} + e_{ij}$ (строки сетевой матрицы). Критерий $F = \rho \sum_i d(y_i, c_{k(i)}) + \xi \sum_i d(p_i, \lambda_{k(i)})$ минимизируется чередованием: правило минимального совместного расстояния и пересчёт центров; инициализация K-means++/MaxMin; версии с евклидовым, косинусным и манхэттенским расстоянием. Сетевое представление узла — двухшаговая диффузия $(T + T^2)/2$ по нормированной смежности, ξ уравнивает суммарный разброс двух пространств; карликовые кластеры ($< 1\% N$) распускаются и пересекаются.

5.2. KEFRiN-T — эволюционная версия

На каждом месяце t кластеризуется сглаженный срез $\tilde{Y}_t = \alpha_t \tilde{Y}_{t-1} + (1 - \alpha_t) Y_t$, $\tilde{P}_t = \beta_t P_t$ и венгерским выравниванием меток. Веса истории — shrinkage-оценка AFFECT: $\alpha_t + (1 - \beta_t) P_t$ с тёплым стартом от $S_{t-1} = \sum \text{var}(\epsilon) / \sum [(\tilde{x}^{t-1} - E x)^2 + \text{var}(\epsilon)]$, где $E x$ берётся из модели KEFRiN. *Наше расширение:* фиксированные эффекты узлов $E y_{iv} = c_{k(i)v} + u_{iv}$ (устойчивое отклонение МО от своего типа; в реальных данных разброс устойчивых эффектов 0,66 втрое больше месячного шума 0,28), робастная (винзоризованная) оценка шума и тест инновации: узел со стандартизованным остатком $z_j > 2,5$ получает $a_j = 0$, его накопленный эффект обнуляется — так настоящая смена типа проходит без задержки. Стартовое разбиение — по среднему первых трёх месяцев; затем второй проход*: алгоритм запускается ещё раз со стартом от модальных (самых частых за 24 месяца) типов первого прохода. Это обычное уточнение к неподвижной точке: первый проход «усаживает» типологию в первые месяцы, второй убирает этот переходный процесс, не меняя модель (см. §8 и рис. 6).

5.3. Проверка на синтетических сетях с известной истиной

Генератор: 600 узлов, 5 сообществ, 12 месяцев; атрибуты $y_{it} = \mu_k + u_i + \epsilon_{it}$; сеть — стохастическая блочная модель с персистентностью рёбер 0,7; в месяц 6 мигрируют 15% узлов, фон

1%/мес. Сценарий «calibrated» повторяет реальные отношения шума, эффектов узлов и расстояний между центрами.

Сценарий	Метод	NMI	мигранты верно через 0/1/2 мес.	ложные смены
калиброванный	KEFRiN-T (эффекты узлов + сброс $z > 2,5$)	0,83	0,74 / 0,85 / 0,89	0,006
калиброванный	KEFRiN-T (сброс $z > 2,5$), второй проход	0,83	0,74 / 0,85 / 0,88	0,007
калиброванный	KEFRiN-T (сброс $z > 2,5$), признаки сглажены скользящим средним 3 мес.	0,81	0,50 / 0,85 / 0,88	0,014
калиброванный	KEFRiN-T, сброс $z > 4$	0,82	0,51 / 0,72 / 0,82	0,006
калиброванный	KEFRiN-T без сброса	0,75	0,05 / 0,33 / 0,68	0,010
калиброванный	AFFECT, блочная модель	0,80	0,32 / 0,72 / 0,85	0,033
калиброванный	фиксированное $\alpha = 0,5$	0,80	0,34 / 0,72 / 0,85	0,032
калиброванный	тёплый старт без сглаживания	0,83	0,88 / 0,91 / 0,92	0,055
калиброванный	K-means по месяцам	0,70	0,85 / 0,86 / 0,86	0,115
калиброванный	temporal Leiden, $\omega = 1$ (только сеть)	0,91	0,41 / 0,80 / 0,93	0,015
низкий шум	KEFRiN-T (эффекты узлов + сброс $z > 2,5$)	0,94	0,68 / 0,85 / 0,88	0,002
низкий шум	тёплый старт без сглаживания	0,94	0,96 / 0,99 / 0,98	0,033
низкий шум	temporal Leiden, $\omega = 1$ (только сеть)	0,92	0,47 / 0,84 / 0,94	0,024
шум $\times 2$	KEFRiN-T (эффекты узлов + сброс $z > 2,5$)	0,76	0,19 / 0,30 / 0,36	0,010
шум $\times 2$	KEFRiN-T (сброс $z > 2,5$), скользящее среднее 3 мес.	0,85	0,20 / 0,57 / 0,70	0,010
шум $\times 2$	фиксированное $\alpha = 0,5$	0,86	0,31 / 0,82 / 0,92	0,035
шум $\times 2$	AFFECT, блочная модель	0,83	0,05 / 0,33 / 0,70	0,013
шум $\times 2$	temporal Leiden, $\omega = 1$ (только сеть)	0,92	0,47 / 0,84 / 0,94	0,024

Средние по 5 сеансам генератора. «Низкий шум»: 8 признаков, σ центров 2, σ эффектов узла 1, σ шума 1; «шум $\times 2$ »: σ шума 2; «калиброванный»: 7 признаков, σ центров 0,78, σ эффектов 0,66, σ шума 0,28 — как в реальных данных.

Первая версия с фиксированными эффектами не замечала настоящих смен (8% мигрантов через два месяца): эффект узла поглощал смену, а оценка шума завышалась самими мигрантами — это и было исправлено робастной оценкой и тестом инновации. Два практических вывода из той же синтетики. Второй проход (старт от модальных типов первого прохода) на синтетике ничего не меняет — там нет переходного процесса, а на реальных данных он убирает всплеск смен первых месяцев (§8). Сглаживание признаков скользящим средним помогает только при сильном шуме (шум $\times 2$: NMI 0,76 $\rightarrow$ 0,85), а при калиброванном шуме вносит запаздывание (мигранты в месяц события 0,74 $\rightarrow$ 0,50) и удваивает ложные смены, поэтому в основной конфигурации не используется. Оговорка: при сильном шуме атрибутов тест инновации почти перестаёт срабатывать, и адаптивная схема становится инерционной (мигранты через два месяца 0,36); там лучше фиксированное $\alpha = 0,5$ (0,92) или чисто сетевой temporal Leiden (0,92, потому что сеть в синтетике не шумит). В реальных данных шум атрибутов мал ($\sigma \approx 0,28$ против разброса центров $\approx 0,8$), режим соответствует калиброванному сценарию, а критичны как раз редкие ложные смены.

5.4. Сравнение методов на статическом срезе 2024 (обученный граф)

Метод	K	SW	CH	S_Dbw	AVI	ANUI	MQ	Q	bootstrap-ARI (B = 10)
K-means	4	0,199	430	0,80	0,82	0,57	3,29	0,56	0,94
KEFRiN (евклид)	4	0,196	429	0,82	0,84	0,58	3,35	0,56	0,95
KEFRiN (косинус)	4	0,192	416	0,81	0,82	0,56	3,29	0,56	0,88
CANUS (Shalileh, 2025; код автора)	4	0,193	372	0,85	0,78	0,53	3,12	0,52	—
DMoN (Tsitsulin et al., 2023; GNN)	4	0,101	353	0,80	0,88	0,56	3,54	0,63	—
Ward	4	0,190	376	0,81	0,73	0,52	2,93	0,48	0,57
GMM	4	0,157	324	0,76	0,68	0,48	2,72	0,44	0,94
KEFRiN (косинус)	6	0,117	310	0,78	0,79	0,55	4,71	0,62	0,70
KEFRiN (евклид)	6	0,144	330	0,78	0,75	0,53	4,48	0,58	0,77
DMoN (GNN)	6	0,091	275	0,75	0,85	0,57	5,11	0,68	—
Leiden, модульность (res 1 / 0,5)	39 / 31	0,01 / 0,04	54 / 54	0,48 / 0,41	0,66 / 0,64	0,59 / 0,60	26 / 20	0,75 / 0,70	0,43 / 0,44
iLouvain (CDlib)	21	−0,04	38	0,26	0,51	0,47	10,6	0,55	—
EVA (CDlib, квартильные категории)	251	−0,21	7	0,06	0,09	0,09	22,4	0,66	—
спектральная по графу	4	0,066	10	0,58	—	—	—	0,01	вырождается

CANUS и DMoN (PyTorch, Adam) при фиксированном seed воспроизводятся между запусками с точностью $\pm 0,01$ по индексам из-за недетерминизма многопоточных операций; остальные методы детерминированы. Совместные least-squares методы дают лучший компромисс между компактностью в пространстве признаков и связностью на сети; чисто сетевые максимизируют модульность ценой дробления на 21–251 сообществ без компактности; DMoN — графовая нейросеть, максимизирующая модульность (реализация по статье, `src/mo_types/dmon.py`), — даёт самую высокую модульность среди методов с заданным K (0,63 при K = 4, 0,68 при K = 6) при вдвое худшей компактности (SW 0,10 против 0,20): та же дилемма «сеть или признаки», что и у Leiden, только с фиксированным K. Это согласуется с выводом Passos, Carlini и Trani (2024) о том, что сложные сетевые и глубокие методы не выигрывают у простых на атрибутированных временных графах.

5.5. Динамические варианты (24 месячных среза, обученные графы, второй проход для всех вариантов)

Вариант	K	AMI соседних месяцев	смена типа/мес.	макс.	МО без смен	SW	Q
тёплый старт без сглаживания	4	0,903	2,3%	3,6%	86%	0,231	0,54
фиксированное $\alpha = 0,5$	4	0,951	1,1%	1,9%	89%	0,232	0,54
AFFECT (блочная модель)	4	0,943	1,2%	2,5%	89%	0,232	0,54
KEFRiN-T без сброса	4	0,971	0,6%	2,9%	90%	0,229	0,53
KEFRiN-T (итог)	4	0,949	1,1%	2,7%	89%	0,231	0,53
тёплый старт	6	0,855	5,4%	7,1%	69%	0,165	0,54
KEFRiN-T (итог)	6	0,932	2,3%	4,3%	77%	0,167	0,52
temporal Leiden, $\omega = 2$ (только сеть)	5	0,993	0,1%	0,3%	97%	0,157	0,55

Итоговый вариант выбран не по максимальной стабильности (её легко получить, запретив смены), а по синтетической проверке: он сочетает низкую долю ложных смен с быстрым обнаружением настоящих. Оценённые веса (со второго месяца; в январе 2023 истории ещё нет, оба веса равны нулю): α_t 0,35–0,88 (медиана 0,75) для признаков, β_t 0,74–0,95 (медиана 0,89) для сети: месячные графы шумнее признаков. Полностью сетевой temporal Leiden на обученных графах находит ровно 5 сообществ с почти неизменным составом — сама обученная сеть имеет ясную модульную структуру; но его разбиение не учитывает контекст и хуже по SW. Что именно находит сеть без признаков (`scripts/network_view.py`): пять сообществ — столичные агломерации (260 из 276 в одном сообществе, чистота 0,87), Север (95 из 195, чистота 0,90), «городское» сообщество (190 городов, доля горожан 0,9) и большое «сельско-полугородское» (1 322 МО: 990 сельских и 271 город, медианная доля горожан 0,4) плюс 14 удалённых районов. Согласие с макротипами AMI 0,48, с подтипами 0,41: сеть сходства потребления сама выделяет столицы и Север, а границу между селом и малыми городами не проводит — её задаёт контекст Росстата. Это ещё один аргумент за совместную кластеризацию признаков и сети вместо любой из половин.

6. Выбор числа типов

Bootstrap-устойчивость (20 подвыборки по 80% МО, статический срез, обученный граф): $K = 4$ — ARI 0,91, минимальный покластерный Жаккар 0,83 (по Hennig, 2007: $> 0,75$ — устойчивый паттерн, $> 0,85$ — высокоустойчивый; три типа из четырёх выше 0,85); $K = 5$ — 0,81; $K = 6$ — 0,74 (нестабильны пограничные типы, Жаккар 0,64–0,71); от $K = 7$ устойчивость совместного критерия падает до 0,57. Индексы качества монотонно убывают с K (SW 0,20 $\rightarrow$ 0,14, CH 429 $\rightarrow$ 330), S_{Dbw} и MQ не дают внутреннего максимума. Поэтому типология двухуровневая: 4 макротипа как устойчивое ядро и 6 подтипов как содержательное уточнение с оговоркой о границах. Кросс-таблица показывает вложенность: города = региональные центры + полугородские промышленные; северные = ресурсные центры + удалённые районы Востока и Сибири; столичные агломерации = один подтип; сельские = сельские и малые + часть полугородских промышленных.

7. Типы и их экономическое содержание

Профили по правилу Миркина (Alvandyan & Shalileh, 2024): d = (среднее по типу – среднее по России)/среднее по России на нестандартизованных признаках.




Рис. 1. Макротипы МО на декабрь 2024 г. Четыре типа образуют устойчивые пояса: столичные агломерации и региональные центры внутри сельского пояса европейской России и юга Сибири, северный и ресурсный пояс от Кольского полуострова до Чукотки.

Макротип	МО	Траты, ₽/мес (медиана)	Общепит	Продовольствие	Население	Зарплата, ₽	Доступность рынков	Отличительная занятость
Крупные и средние города	508	29 295	4,1%	41%	56 тыс.	68 898	322	промышленность +101%
Северные и ресурсные	195	34 491	3,4%	43%	21 тыс.	111 491	149	добыча ×6,8
Столичные агломерации	276	46 751	7,8%	32%	77 тыс.	127 498	561	рыночные услуги +115%
Сельские и малые	1 037	21 352	1,6%	47%	16 тыс.	50 273	318	сельское хозяйство +61%

- **Крупные и средние города** (Новосибирск, Казань, Нижний Новгород, Красноярск): население +111% к среднему, доля горожан +55%, промышленность +101%, траты около средних (+5%), общепит +23%.
- **Северные и ресурсные** (Якутск, Петропавловск-Камчатский, Сургутский район, Нефтеюганск): добыча +578%, зарплата +53%, траты +26%, доступность рынков –47%, маркетплейсы –27% (логистика), здоровье –19%.
- **Столичные агломерации** (Москва и Санкт-Петербург с внутригородскими территориями, Подмоскowie, Екатеринбург, Тюмень): общепит +129%, траты +64%, зарплата +83%, доступность рынков +60%, продовольствие –26% — закон Энгеля в чистом виде.
- **Сельские и малые** (половина панели): продовольствие +9%, общепит –47%, траты –24%, население –67%, зарплата –31%, сельское хозяйство +61%, бюджетная занятость +21%.

Подтипы добавляют: **удалённые районы Востока и Сибири** (152; доступность рынков –48%, транспорт +15%, сезонность +14%, маркетплейсы –26%), **северные ресурсные центры** (116; добыча ×11,8, зарплата +70%), **региональные центры** (313; население +212%, промышленность +118%), **полугородские промышленные районы** (486; профиль близок к среднему, промышленность +28%).




Рис. 2. Восемь самых отклоняющихся признаков каждого макротипа (правило Миркина, % к среднему по России) и пороговые правила IMM-дерева.

Пороговые правила IMM-дерева (Dasgupta et al., 2020) на сырых признаках объясняют макротип с точностью 80%: столичные агломерации — доля общепита $> 6\%$; северные и ресурсные — общепит $\leq 6\%$ и зарплата $> 93,4$ тыс. P ; города — общепит $\leq 6\%$, зарплата $\leq 93,4$ тыс. P и траты $> 25,9$ тыс. $\text{P}/\text{мес}$; сельские и малые — остальное. Суррогатное дерево с 8 листьями воспроизводит 89% меток.

Внешняя валидация: типы объясняют 74% дисперсии уровня трат, 64% зарплат, 58% доступности рынков (η^2); согласие с административным типом МО умеренное (ARI 0,37), с регионом — слабое (0,04): типология не повторяет ни административную сетку, ни регионы. Независимый набор СберИндекса, не участвовавший в кластеризации, — индекс покупательской мобильности (км, конец 2024 г.; 270 из 297 МО сопоставлены по названию, `scripts/mobility_check.py`) — различает типы так же резко: медианы 4,8 км у столичных агломераций, 1,1 у городов, 0,9 у северных, 0,5 у сельских ($\eta^2 = 0,51$, тест Краскела–Уоллиса $p < 10^{-30}$).

7.4. Вторая линза: типы потребительского поведения только по данным СберИндекса

Экономическая типология выше строится на потреблении вместе с контекстом Росстата. Отсюда вопрос: что в ней от данных СберИндекса? Статическая KEFRiN на тех же графах даёт: полные признаки — ARI 0,86 с итоговыми макротипами, только контекст (население, зарплата, занятость, доступность) — 0,71, только потребление — 0,44. Потребление само по себе безошибочно выделяет столичные агломерации (97% МО типа) и село (74%), но не разделяет города и Север: их различает контекст. Поэтому мы добавляем вторую линзу — **поведенческую типологию** тем же методом (KEFRiN-T на обученных графах), но только по семи месячным признакам потребления: CLR-

структура шести категорий и относительный уровень трат (scripts/two_lenses.py, outputs/two_lenses/).

Число типов — 5: по бутстрапу это единственное устойчивое решение (ARI 0,86, минимальный Жаккар 0,84 против 0,82 при K = 4 и 0,67 при K = 6). Поведенческие типы менее устойчивы во времени, чем экономические (46% МО без смен за два года против 89%, смена типа 6,1% в месяц): без контекста, который не меняется, типы «дышат» вместе с сезоном и волной маркетплейсов. Пороговые правила на сырых долях объясняют их с точностью 74% (суррогатное дерево с 10 листьями — 80%): общепит > 5% — «общепит и услуги»; иначе маркетплейсы ≤ 12% — «дорогая корзина без онлайн»; иначе транспорт > 6% — «транспортная корзина»; иначе доля прочего > 24% — «базовая корзина малых городов», ≤ 24% — «продукты и маркетплейсы».




Рис. 5. Поведенческая линза (только СберИндекс): карта пяти типов потребления, кросс-таблица с экономической типологией (число МО и доля строки), профили по правилу Миркина.

Поведенческий тип	МО	Общепит	Маркетплейсы	Продовольствие	Транспорт	Траты, % к среднему	Примеры
Общепит и услуги	467	+105%	–14%	–21%	+25%	+48%	Новосибирск, Екатеринбург, Казань, Нижний Новгород
Базовая корзина малых городов	565	–22%	+8%	+4%	–20%	–11%	Орск, Белово, Муром, Димитровград
Продукты и маркетплейсы	503	–61%	+19%	+12%	–9%	–27%	Изобильненский, Кочубеевский, Петровский округа
Транспортная корзина	364	–17%	–7%	+3%	+15%	–18%	Курган, Балаково, Бийск, Златоуст
Дорогая корзина без онлайн	117	+4%	–40%	+3%	–13%	+32%	Якутск, Комсомольск-на-Амуре, Норильск, Магадан

Две линзы согласуются лишь частично (ARI 0,28, AMI 0,41), и именно расхождения содержательны. Столичные агломерации почти целиком (271 из 276) попадают в «общепит и услуги», а северные и ресурсные — в «дорогую корзину без онлайн» (109 из 195): для этих типов экономика и поведение совпадают. Крупные и средние города делятся между «общепитом и услугами» (169) и «базовой корзиной» (248): половина городов по потреблению живёт как малые города. Сельский тип распадается на три корзины: «продукты и маркетплейсы» (493, чистота 98% — это самое сельское потребление в стране), «базовая» (273) и «транспортная» (264) — сельские районы вдоль трасс и с высокой долей расходов на топливо. Итог для интерпретации: экономическая линза отвечает на вопрос «какая это территория», поведенческая — «как здесь тратят», и вторая не выводится из первой.

8. Динамика типов

Типы — устойчивые состояния: за два года их не меняли большинство МО



Рис. 3. Потоки между макротипами по полугодиям, доля МО, сменивших тип за месяц, оценённые веса истории α_t и β_t , месячная матрица переходов и размеры типов.

- Чистка динамики: второй проход.** Первый проход стартует с разбиения по среднему первых трёх месяцев, и типология «усаживается» несколько месяцев: согласие меток января–марта 2023 с модальным типом 0,82, всплеск 78 смен в июне 2023 (Казань, Уфа, Владивосток, Хабаровск переходят из столичного типа в города — граница инициализации, а не экономика). Второй проход со стартом от модальных типов первого прохода убирает переходный процесс, не меняя модель: смен за два года 752 → 579 (–23%), июнь 2023 — 78 → 36, ноябрь–декабрь в среднем 49 → 35, остальные месяцы 28 → 23; согласие первых месяцев с модальным типом 0,82 → 0,85; модальный тип не изменился у 98,9% МО (ARI 0,97). Остаточная сезонность сохраняется: ноябрь–декабрь дают в полтора раза больше смен, чем лето (новогодний сдвиг структуры трат); сглаживание признаков скользящим средним её убирает, но по синтетике вносит запаздывание и ложные смены при низком шуме (§5.3), поэтому не применено (scripts/dynamics_cleanup.py, outputs/dynamics_cleanup/).




Рис. 6. Число смен типа по месяцам до (старт по первым трём месяцам) и после второго прохода: макротипы и подтипы.

- **Устойчивость:** диагональ матрицы месячных переходов 0,96–0,997 (ожидаемое пребывание от 25 месяцев у северных до десятков лет у столичных); 89% МО не меняли макротип ни разу; смены сосредоточены в пограничных сельских районах и малых городах.
- **Пространственная обусловленность** (Spatial Markov, 8 ближайших МО по дорожной сети): если соседи — северные и ресурсные, вероятность перейти в этот тип 39% против базовой 0,4% (оценка на малом числе смен); для городов 2,7% против 0,9%. Смена типа — не изолированное событие, а движение вместе с окружением.
- **Сходимости уровней нет:** тест log-t Phillips–Sul отвергает сходимость и в целом ($b = -0,77$, $t = -28,7$), и внутри каждого типа; дисперсия относительных уровней H_t выросла с 0,10 в январе 2023 до 0,13 в 2024 г., std логарифма уровня — с 0,29 до 0,33. Оговорка: рост может отражать неравномерное проникновение безналичных платежей.
- **Кейсы шоков:** паводок в Орске (ЧС федерального уровня, апрель 2024) не изменил тип города; относительно медианы типа уровень трат в апреле $-0,01$, в мае $+0,05$ (выплаты), затем возврат к норме. Приграничные регионы в панели отсутствуют.

9. Волна маркетплейсов: единственный большой сдвиг структуры трат

Типы устойчивы, но внутри них структура трат за два года изменилась в одном направлении: доля маркетплейсов удвоилась. Это единственный сдвиг такого масштаба в данных, и он не разрушает типологию, потому что идёт во всех типах сразу (`scripts/marketplace_wave.py`, `outputs/marketplace_wave/`).

Прирост доли маркетплейсов в тратах по МО за год (среднее 2024 – среднее 2023, п.п.)




Рис. 4. Прирост доли маркетплейсов за год по МО (среднее 2024 – среднее 2023), доля по макротипам по месяцам и прирост по типам (медиана и межквартильный размах).

- **Масштаб.** Средняя по МО доля маркетплейсов выросла с 9,4% в январе 2023 до 19,3% в декабре 2024 (взвешенно по населению 8,8% → 17,4%); пик 2023 года — ноябрь, в 2024-м максимум сместился на декабрь. Медианный прирост среднегодовой доли 4,1 п.п., отрицательного прироста нет ни у одного МО. Доля продовольствия за то же время снизилась с 44,6% до 41,6%, общепита — с 3,5% до 2,8%.
- **Догоняющий рост.** Прирост тем больше, чем меньше население, ниже зарплата и доля горожан и чем ниже стартовая доля: сельские и малые МО +4,8 п.п. в год, северные +3,9, города +3,7, столичные агломерации +2,5 (медианы). Сельские МО уже в 2023 г. тратили на маркетплейсах больше столиц (12,6% против 10,6%), а в 2024 г. — 17,5% против 13,1%: онлайн замещает отсутствующую офлайн-торговлю. Корреляция прироста доли с приростом доли продовольствия $-0,39$: маркетплейсы забирают долю прежде всего у продовольственного ретейла.
- **Доступность рынков не объясняет волну.** В регрессии прироста на логарифмы доступности, населения, зарплаты, долю горожан, стартовую долю и тип коэффициент при доступности +0,23 п.п. ($t = 2,1$), а с фиксированными эффектами регионов $-0,88$ ($t = -3,6$); только по сельским МО +0,51 ($t = 2,7$) и +0,23 ($t = 0,4$) с эффектами регионов. Знак зависит от спецификации, поэтому эффект дорожной доступности мы не считаем установленным; устойчивы эффекты населения ($-0,3...-0,7$ п.п. на единицу логарифма), урбанизации ($-0,6...-0,8$) и стартовой доли ($-0,1...-0,2$ п.п. на 1 п.п.). R^2 0,47 без и 0,60 с региональными эффектами.

- **Два полюса отставания.** Медленнее всего доля растёт там, где доставки нет, и там, где она не нужна: арктические районы Якутии и Чукотки (доля 3–5% в 2024 г., прирост 1–1,7 п.п.) и центральные районы Москвы (Тверской, Якиманка, Хамовники, Арбат: около 10%, прирост 1,6–1,7 п.п.). Лидеры — отдалённые сельские районы Сибири и Дальнего Востока с низкой стартовой долей: Мотыгинский район Красноярского края 4,6% → 19,5%, Солтонский район Алтайского края 5,2% → 17,5%, Усть-Ишимский район Омской области 4,9% → 16,2%.
- **Клубная сходимость.** Разброс доли между всеми МО вырос с 2,7 до 4,1 п.п. (std), но внутри типов он не растёт (село 3,2 → 3,1 п.п., города 2,4 → 2,5). Тест log-t по доле маркетплейсов отвергает сходимость по всей панели ($b = -0,25$, $t = -6,2$) и внутри городов и столичных агломераций, но не отвергает её внутри сельского ($b = 0,09$) и северного ($b = -0,08$) типов: типы расходятся между собой, а внутри двух самых массовых типов доли сближаются. Типология, таким образом, задаёт клубы сходимости и для структуры трат.

10. Индексы качества (ICVI)

Признаковое пространство: SW (silhouette), CH (Calinski–Harabasz), S_Dbw (Halkidi & Vazirgiannis). Сетевое: AVI, AVU, ANUI (Biswas & Biswas, 2017), MQ (Mancoridis et al., 1998, взвешенный TurboMQ), модульность Ньюмана и density modularity. Реализация AVU/AVI/ANUI/модульности сверена с библиотекой Pattern (тест `tests/test_metrics.py`). Итоговая типология: K = 4 — SW 0,23, CH 491, S_Dbw 0,80, AVI 0,81, AVU 0,52, ANUI 0,57, MQ 3,23, Q 0,53 (средние по 24 месяцам); K = 6 — SW 0,17, CH 387, S_Dbw 0,76, AVI 0,68, ANUI 0,51, MQ 4,08, Q 0,52.

11. Воспроизводимость

`make env` создаёт окружение (Python 3.12, `requirements.txt`, `graph-learning` из git), `scripts/download_data.py` скачивает все источники (с проверкой sha256; показатели Росстата извлекаются из больших архивов по HTTP Range), `make all` прогоняет пайплайн от панели до лендинга и отчёта (`scripts/build_report.py` собирает этот документ из `report/methodology.md`); все гиперпараметры — в `configs/base.yaml` и `configs/types.yaml`; `seed = 42`. Два контрольных прогона с нуля (21.09.2026, 26 и 40 мин на Apple M-серии) воспроизвели итоговые метки типов, интерпретацию, волну маркетплейсов и обе линзы побайтно; во втором прогоне из 151 файла результатов 142 совпали полностью, остальные отличались только временем счёта и индексами CANUS/DMoN в третьем знаке. В первом прогоне статический обученный граф отличался на ± 2 ребра (солвер `graph-learning`), поэтому сравнительные таблицы §5.4 и §6 могут меняться в третьем знаке, bootstrap-ARI — до $\pm 0,03$. Проприетарные платные технологии не используются; все пакеты открытые.

12. Ограничения и что дальше

24 месяца — короткий горизонт для сезонности и для теста сходимости; в панели нет 12 регионов; значение расходов — модельная оценка СберИндекса (порог качества), а «прочее» — остаток. Для продолжения: обучение графа с учётом контекста (расстояния между МО по признакам Росстата), нелинейное сходство (представления TS2Vec), проверка типологии на данных 2025 г. (out-of-time), поиск лидеров и последователей на более длинных рядах (на 24 месяцах лаговые корреляции не дали сигнала, §4).

Литература

Shalileh S., Mirkin B. Community partitioning over feature-rich networks using an extended K-means method. *Entropy*, 2022. · Shalileh S., Antonov E., Tsyplakova D. Profiling consumption using attributed network clustering. *Complex Networks & Their Applications XIV*, 2026. · Shalileh S. A filtered gradient descent clustering method to recover communities in attributed networks. *IEEE Access*, 2025. · Alvandyan T., Shalileh S. An empirical scrutinization of four crisp clustering methods with four distance metrics and one straightforward interpretation rule. *Doklady Mathematics*, 2024. · Xu K., Kliger M., Hero A. Adaptive evolutionary clustering. *Data Mining and Knowledge Discovery*, 2014. · Chakrabarti D., Kumar R., Tomkins A. Evolutionary clustering. *KDD*, 2006. · Kalofolias V. How to learn a graph from smooth signals. *AISTATS*, 2016; Kalofolias V., Perraudin N. Large scale graph learning from smooth signals. *ICLR*, 2019. · Yamada K., Tanaka Y., Ortega A. Time-varying graph learning with constraints on graph temporal variation. 2020. · Mucha P. et al. Community structure in time-dependent, multiscale, and multiplex networks. *Science*, 2010. · Rossetti G., Cazabet R. Community discovery in dynamic networks: a survey. *ACM Computing Surveys*, 2018. · Biswas A., Biswas B. Defining quality metrics for graph clustering evaluation. *Expert Systems with Applications*, 2017. · Halkidi M., Vazirgiannis M. Clustering validity assessment. *ICDM*, 2001. · Mancoridis S. et al. Using automatic clustering to produce high-level system organizations of source code. 1998. · Dasgupta S., Frost N., Moshkovitz M., Rashtchian C. Explainable k-means and k-medians clustering. *ICML*, 2020. · Hennig C. Cluster-wise assessment of cluster stability. *CSDA*, 2007. · Phillips P., Sul D. Transition modeling and econometric convergence tests. *Econometrica*, 2007. · Rey S. Spatial empirics for economic growth and convergence. *Geographical Analysis*, 2001. · Wang B. et al. Similarity network fusion. *Nature Methods*, 2014. · Serrano M. et al. Extracting the multiscale backbone of complex weighted networks. *PNAS*, 2009. · Passos N., Carlini E., Trani S. Deep community detection in attributed temporal graphs: experimental evaluation. *GNNet*, 2024.